GOBIERNO DEL ESTADO DE MÉXICO

UPA ATLAUTLA
UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

Universidad Politécnica de Atlautla

2 parcial

Programa: Ing. en Tecnologías de la Información e Innovación Digital

Asignatura: Fundamentos de Inteligencia Artificial

Tema: Actividad Integrador 3.1

Tipos de aprendizaje automático

Docente: Mtro. Javier García Lara

Alumno: Anahi Fuentes Avendaño

Enlace de GitHub:

https://github.com/fana60203/FIA_G171_Anahi_Fuentes

Grupo: 171

Fecha de entrega: 06 – Noviembre - 2026

Índice

Objetivo General 3

Sección 1. Investigación 3

1.1 Investigación conceptual 3

1.1.1 Concepto de Aprendizaje Automático 3

Sección 2. Modelados 5

2.1 Grafo de taxonomía del ML 5

2.2 Diagrama de flujo del ciclo de vida de un modelo de ML 6

2.3 Tabla comparativa de métricas de evaluación 6

Conclusión 8

Referencias 9

Objetivo General

Comprender, clasificar y modelar los tipos de aprendizaje automático, identificando sus características y aplicaciones reales, para finalmente argumentar por escrito la resolución de una problemática social aplicando el modelo de IA más adecuando

Sección 1. Investigación

Objetivo: Comprender el concepto de aprendizaje automático, sus características, clasificación y aplicaciones, mediante investigación documental y digital.

1.1 Investigación conceptual

1.1.1 Concepto de Aprendizaje Automático

¿Qué es el aprendizaje automático?

El aprendizaje automático es una forma de hacer que una computadora aprenda a partir de ejemplos. En vez de decirle paso a paso qué hacer, le damos muchos datos y el algoritmo encuentra por sí solo los patrones, para después usarlos con información nueva que nunca ha visto.

Definición citada 1: IBM lo describe como la parte de la inteligencia artificial centrada en algoritmos que “aprenden” los patrones de los datos de entrenamiento y, después, hacen inferencias acertadas sobre datos nuevos (Bergmann, 2026).

Definición citada 2: Microsoft lo define como un subconjunto de la inteligencia artificial que usa técnicas con las que las máquinas aprovechan la experiencia para mejorar su capacidad de realizar tareas (Microsoft, 2025a).

¿Qué diferencia existe entre programación tradicional y aprendizaje automático?

En la programación tradicional la persona escribe las reglas y el programa las aplica a los datos para obtener respuestas. En el aprendizaje automático se invierte el camino: se entregan datos junto con las respuestas esperadas y el algoritmo aprende las reglas (el modelo), que luego se aplican a datos nuevos (Bergmann, 2026).

Aspecto	Programación tradicional	Aprendizaje automático
Entradas	Datos + reglas escritas por el programador	Datos + respuestas (etiquetas) o recompensas
Salida del proceso	Respuestas	Reglas aprendidas, es decir, el modelo entrenado
Quién define la lógica	La persona, de forma explícita	El algoritmo, a partir de los datos
Cuándo conviene	Reglas claras y estables (calcular una nómina, validar un formulario)	Reglas difíciles de describir (reconocer rostros, filtrar spam, recomendar contenido)
Adaptación al cambio	Hay que modificar y volver a desplegar el código	Se reentrena con datos nuevos
De qué depende la calidad	De que la lógica esté bien escrita	De la cantidad y la calidad de los datos
Riesgos típicos	Errores de programación (bugs)	Sesgos, datos deficientes, sobreajuste

¿Qué es un dataset, una etiqueta, una feature y una función de pérdida?

Dataset (conjunto de datos): conjunto de ejemplos (filas) descritos por variables (columnas) que sirve para entrenar y evaluar un modelo (Google for Developers, 2025a, 2025c).

Etiqueta (label): lo que se quiere predecir; se representa con y (Google for Developers, 2025b, 2025c). En el aprendizaje no supervisado los datos no tienen etiquetas (Microsoft, 2025b).

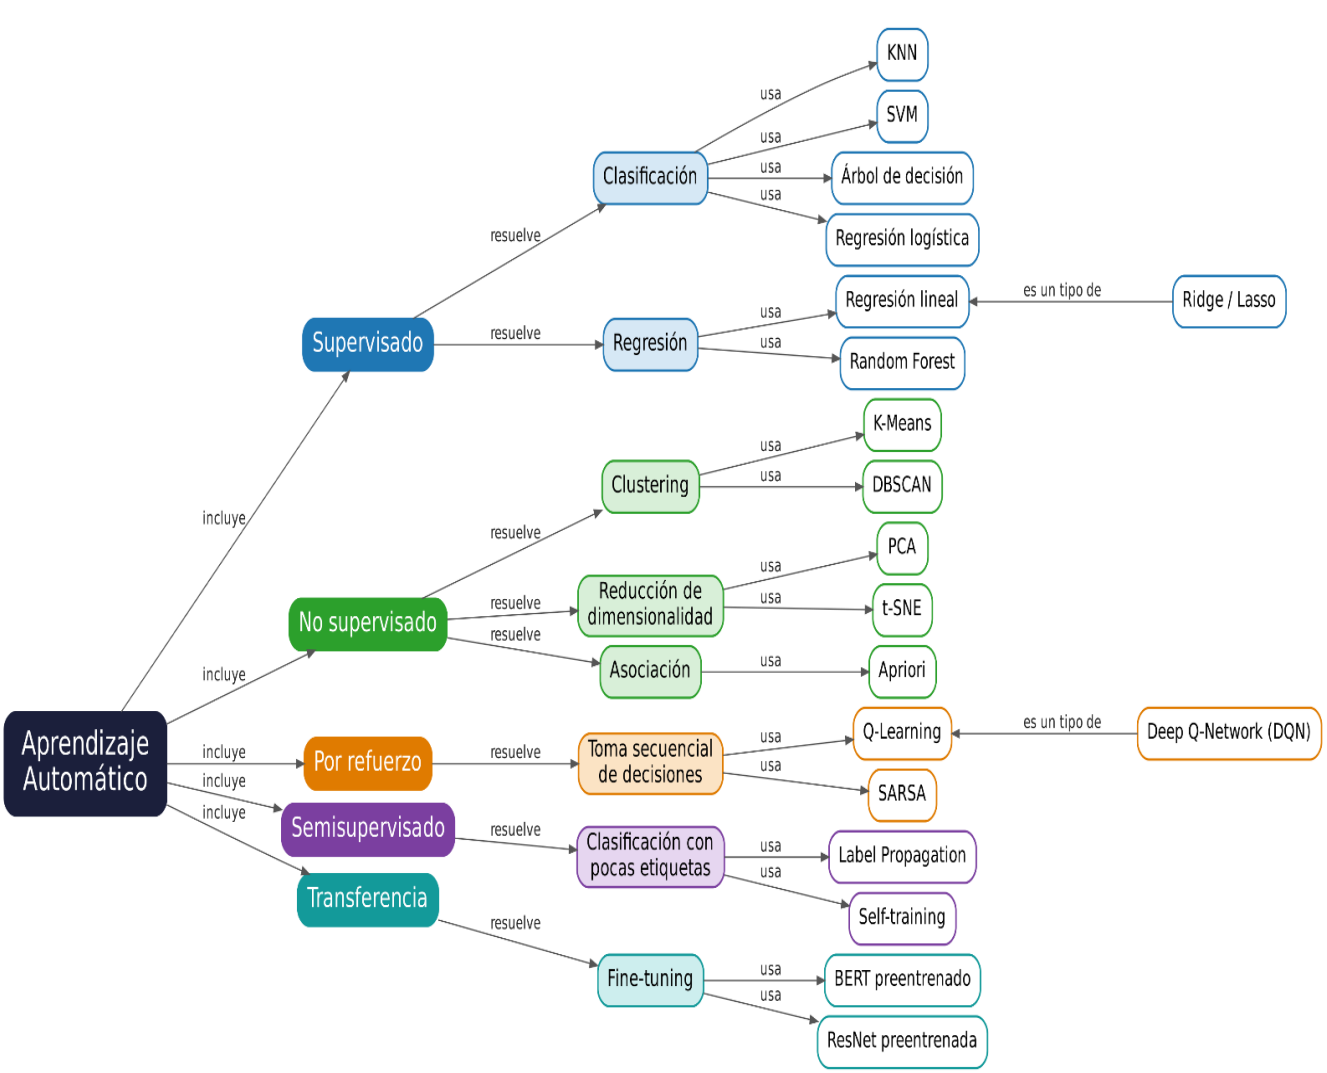
Feature (característica): variable de entrada que describe cada ejemplo; se representa con x o $x_1, x_2, \ldots, x_n$ (Google for Developers, 2025b).

Función de pérdida (loss function): número que indica qué tan mala fue una predicción en un ejemplo. Vale cero cuando la predicción coincide con el valor real y crece conforme aumenta el error. El entrenamiento busca minimizar la pérdida promedio (Google for Developers, 2026).

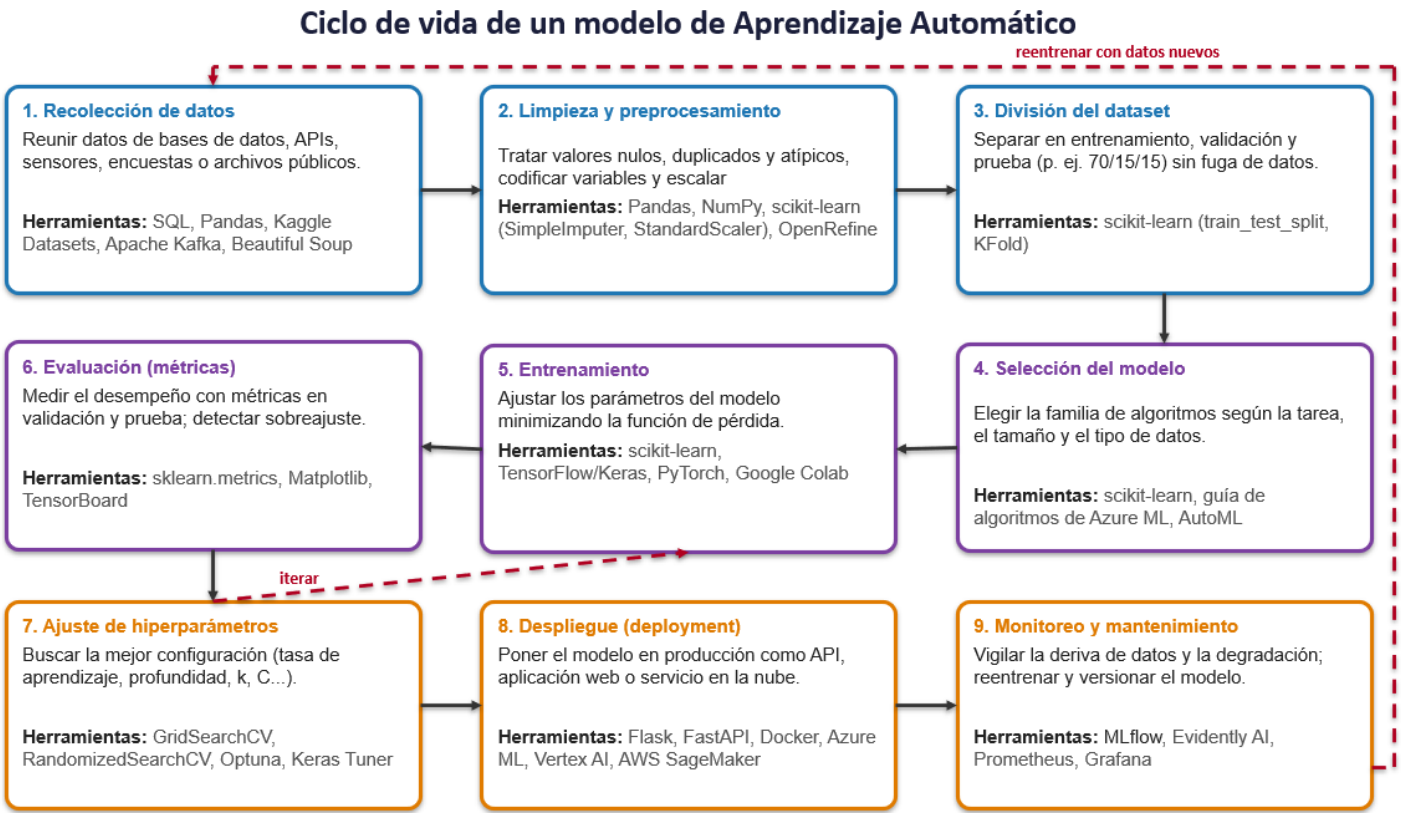
Sección 2. Modelados

Objetivo: Representar gráfica y matemáticamente los tipos de aprendizaje automático mediante grafos, diagramas y modelos formales.

2.1 Grafo de taxonomía del ML



2.2 Diagrama de flujo del ciclo de vida de un modelo de ML



2.3 Tabla comparativa de métricas de evaluación

TIPO DE ML	MÉTRICAS TÍPICAS	FÓRMULA / DEFINICIÓN
Supervisado (clasificación)	Exactitud (accuracy)	(VP + VN) / (VP + VN + FP + FN)
	Precisión	VP / (VP + FP)
	Exhaustividad (recall)	VP / (VP + FN)
	F1	2 · Precisión · Exhaustividad / (Precisión + Exhaustividad)

	AUC-ROC	Área bajo la curva que relaciona la tasa de verdaderos positivos con la de falsos positivos
	Log loss	$-(1/N)\,\Sigma\,[\,y\cdot\log(p) + (1-y)\cdot\log(1-p)\,]$
Supervisado (regresión)	MAE	$(1/n)\,\Sigma\,\lvert y_i - \hat{y}_i\rvert$
	MSE	$(1/n)\,\Sigma\,(y_i - \hat{y}_i)^2$
	RMSE	$\sqrt{\text{MSE}}$
	R^2 (coeficiente de determinación)	$1 - \Sigma\,(y_i - \hat{y}_i)^2 \,/\, \Sigma\,(y_i - \bar{y})^2$
No supervisado	Coeficiente de silueta	$s = (b - a) / \max(a, b)$, con *a* = distancia media dentro del grupo y *b* = distancia media al grupo más cercano
	Inercia (WCSS)	$\Sigma_k\,\Sigma_{x\,\in\,\text{grupo}\,k}\,\lVert x - \mu_k\rVert^2$ (suma de las distancias al cuadrado de cada punto al centroide de su grupo)
	Índice Davies-Bouldin	Promedio de la mayor razón entre dispersión interna y separación entre grupos; menor es mejor
	Varianza explicada (PCA)	$\lambda_i \,/\, \Sigma_j\,\lambda_j$ (proporción de varianza que retiene cada componente)
Por refuerzo	Retorno (recompensa acumulada)	$G_t = \Sigma_{k=0}^{\infty}\,\gamma^k \cdot r_{t+k+1}$, con $\gamma \in [0, 1]$ como factor de descuento
	Recompensa promedio por episodio	$(1/E)\,\Sigma_{e=1}^{E}\,R_e$
	Tasa de éxito	Episodios que alcanzan la meta / total de episodios
	Arrepentimiento (regret)	$\Sigma_t\,(r^* - r_t)$, diferencia frente a la mejor recompensa posible

Conclusión

Después de investigar, me quedó claro que el aprendizaje automático no es magia, es una computadora que aprende de ejemplos en lugar de seguir reglas escritas a mano. Hay datos (el dataset), hay lo que describe cada caso (las features), hay la respuesta que queremos (la etiqueta) y hay una forma de medir qué tan mal lo hace el modelo (la pérdida), que es lo que se va reduciendo al entrenar.

También vi que no todo el ML es igual, según los datos que tengas, usas supervisado, no supervisado, por refuerzo, semisupervisado o transferencia. Los diagramas me sirvieron para ordenar todo, y el ciclo de vida me enseñó que entrenar el modelo es solo una parte. Después hay que evaluarlo, ajustarlo, ponerlo a funcionar y vigilarlo, porque los datos cambian con el tiempo.

Declaración de uso de IA generativa. Se utilizó Claude (Anthropic, 2026) para proponer la estructura del grafo de taxonomía y del diagrama de flujo.

Declaración de uso de IA generativa. Se utilizó Gemini (Google, 2026) para revisar y verificar la información que se investigo y que las referencias fueran correctas en Apa 7

Referencias

Bergmann, D. (2026, 2 de octubre). *What is machine learning?* IBM. Recuperado el 5 de noviembre de 2026, de https://www.ibm.com/think/topics/machine-learning

Google for Developers. (2025a, 3 de diciembre). *Datasets: Data characteristics*. Machine Learning Crash Course. Recuperado el 5 de noviembre de 2026, de https://developers.google.com/machine-learning/crash-course/overfitting/data-characteristics

Google for Developers. (2025b, 9 de diciembre). *Linear regression*. Machine Learning Crash Course. Recuperado el 5 de noviembre de 2026, de https://developers.google.com/machine-learning/crash-course/linear-regression

Google for Developers. (2025c, 25 de agosto). *Supervised learning*. Machine Learning Crash Course. Recuperado el 5 de noviembre de 2026, de https://developers.google.com/machine-learning/crash-course/framing/ml-terminology

Google for Developers. (2026, 5 de enero). *Linear regression: Loss*. Machine Learning Crash Course. Recuperado el 5 de noviembre de 2026, de https://developers.google.com/machine-learning/crash-course/linear-regression/loss

Hugging Face. (s. f.). *The reinforcement learning framework*. Deep Reinforcement Learning Course. Recuperado el 5 de noviembre de 2026, de https://huggingface.co/learn/deep-rl-course/unit1/rl-framework

Microsoft. (2025a, 13 de octubre). *Deep learning vs. machine learning*. Microsoft Learn. Recuperado el 5 de noviembre de 2026, de https://learn.microsoft.com/en-us/azure/machine-learning/concept-deep-learning-vs-machine-learning?view=azureml-api-2

Microsoft. (2025b, 13 de agosto). *Machine learning algorithm cheat sheet for Azure Machine Learning designer*. Microsoft Learn. Recuperado el 5 de noviembre de 2026, de https://learn.microsoft.com/en-us/azure/machine-learning/algorithm-cheat-sheet

scikit-learn developers. (s. f.-a). *3.4. Metrics and scoring: quantifying the quality of predictions* (versión 1.9.1). scikit-learn. Recuperado el 5 de noviembre de 2026, de https://scikit-learn.org/stable/modules/model_evaluation.html

scikit-learn developers. (s. f.-b). *davies_bouldin_score* (versión 1.9.1). scikit-learn. Recuperado el 5 de noviembre de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.metrics.davies_bouldin_score.html

scikit-learn developers. (s. f.-c). *KMeans* (versión 1.9.1). scikit-learn. Recuperado el 5 de noviembre de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

scikit-learn developers. (s. f.-d). *silhouette_score* (versión 1.9.1). scikit-learn. Recuperado el 5 de noviembre de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html